

操作保存

SGLang 在线推理服务挑战 · 服务启动、在线验证与 Mooncake 压测全过程的终端实录

截图1 启动 SGLang 0.5.14 服务并验证在线推理

在 WSL2 (Ubuntu 26.04) 中以 OpenAI-compatible 方式启动 SGLang, `--device cpu --tp 1`。日志显示: 平台不支持 Intel AMX 时自动回退 `torch_native` 后端; KV Cache 分配 `81261 tokens` (K/V 各 4.34 GB, bf16) ; `max_total_num_tokens=81261`、`chunked_prefill_size=2048`、`max_prefill_tokens=16384`、`context_len=40960`; `RadixCache` 已初始化。随后 `GET /v1/models` 返回模型信息, `POST /v1/chat/completions` 完成一次真实推理 (prompt 36 tokens / completion 256 tokens, 达到 `max_tokens=256` 上限, `finish_reason=length`) 。

截图1 - 启动 SGLang 服务并验证推理

WSL2 Ubuntu 26.04 | Qwen3-0.6B | CPU

```

$ uname -sr && nproc
Linux 6.18.33.2-microsoft-standard-WSL2
12 vCPU

# 以 OpenAI-compatible 方式在 CPU 上启动 SGLang 0.5.14
$ python -m sglang.launch_server --model-path /opt/sgl-workspace/models/Qwen3-0.6B --device cpu --tp 1 \
    --host 127.0.0.1 --port 30000 --trust-remote-code --disable-overlap-schedule

[2026-09-26 10:48:21] The current platform does not support Intel AMX, will fallback to torch_native backend.
[2026-09-26 10:48:30] Load weight end. elapsed=0.35 s, type=Qwen3ForCausalLM, avail mem=11.34 GB, mem usage=1.03 GB.
[2026-09-26 10:48:34] KV Cache is allocated. dtype: torch.bfloat16, #tokens: 81261, K size: 4.34 GB, V size: 4.34 GB
[2026-09-26 10:48:34] max_total_num_tokens=81261, chunked_prefill_size=2048, max_prefill_tokens=16384, max_running_requests=2048, context_len=40960...
[2026-09-26 10:48:34] Tree cache initialized: source=default impl=RadixCache hybrid_swa=False hybrid_ssm=False hierarchical=False streaming_wrapped...
[2026-09-26 10:48:35] INFO:      Application startup complete.
[2026-09-26 10:48:35] INFO:      Uvicorn running on http://127.0.0.1:30000 (Press CTRL+C to quit)

# 说明: 本机无 AMX/AVX-512, SGLang 自动回退 attention_backend=torch_native;
#       RadixCache 已启用 (Tree cache initialized ... impl=RadixCache) 。

=====

$ curl -s http://127.0.0.1:30000/v1/models | python -m json.tool
{
  "object": "list",
  "data": [
    {
      "id": "/opt/sgl-workspace/models/Qwen3-0.6B",
      "object": "model",
      "created": 1790390946,
      "owned_by": "sglang",
      "root": "/opt/sgl-workspace/models/Qwen3-0.6B",
      "parent": null,
      "max_model_len": 40960
    }
  ]
  ...
}

=====

$ curl -s http://127.0.0.1:30000/v1/chat/completions -H 'Content-Type: application/json' -d '
{"model": "Qwen/Qwen3-0.6B",
 "messages": [{ "role": "system", "content": "You are a concise assistant."},
               { "role": "user", "content": "用三句话说明 SGLang 的 RadixAttention 解决了什么问题。"}],
 "max_tokens": 256, "temperature": 0.7, "stream": false}'

id            : 8c361cc50b204ed9b105fafecc5c3261
model         : Qwen/Qwen3-0.6B
finish_reason  : length
usage         : {"prompt_tokens": 36, "total_tokens": 292, "completion_tokens": 256, "prompt_tokens_details": null, "reasoning_tokens": 0}
回答正文 (截断显示) :
    SGLang的RadixAttention解决了大规模序列处理中的计算效率瓶颈, 通过将注意力机制分解为多个

--- 补充: 一次短提示的真实往返 (便于观察 TTFT 与 token 统计) ---
$ curl -s http://127.0.0.1:30000/v1/completions -H 'Content-Type: application/json' \
    -d '{"model": "Qwen/Qwen3-0.6B", "prompt": "Count from 1 to 50.", "max_tokens": 64, "ignore_eos": true}'
choices[0].text : ' How many numbers are there in the set {1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, ' ...
finish_reason   : length
usage           : {"prompt_tokens": 9, "total_tokens": 73, "completion_tokens": 64, "prompt_tokens_details": null, "reasoning_tokens": 0}
            
```

截图2a Mooncake FAST'25 trace 采样 + Poisson 到达压测

从 [mooncake_trace.jsonl](#) (共 23608 条) 随机采样 20 条, 按每条记录的 `input_length / output_length` 构造 synthetic prompt; 相邻到达间隔服从指数分布, 即严格的泊松到达过程 ($\lambda = 0.5$ req/s, 平均间隔 2.0 s)。逐条记录 `input tokens / output tokens / status / TTFT / latency`。

截图2a · Mooncake trace 采样 + Poisson 压测 (参数与逐请求过程) 20 req | $\lambda=0.5/s$ | seed=2026

```
$ python 04_benchmark.py --n 20 --mean-interval 2.0 --input-cap 1024 --out-cap 64 --seed 2026
```

```
=====
Mooncake FAST'25 trace 采样 + Poisson 到达 workload
=====
```

```
trace 文件      : /mnt/d/first-task/data/mooncake_trace.jsonl
trace 记录总数  : 23608
采样条数       : 20 (seed=2026)
语料 token 数  : 6120 (需要 >= 1024)
泊松到达       :  $\lambda = 0.5000$  req/s (平均间隔 2.00s), 总到达跨度 58.8s
输入长度区间   : 917 ~ 1024 tokens
输出长度区间   : 8 ~ 64 tokens
公共前缀       : 256 tokens (对应 trace 的 hash_ids[0] 共享前缀)
```

```
[warmup 1] status=200 ttft=193ms latency=1042ms err=None
```

[1/20]	req#7	in=1024	out=23	status=ok	ttft=5307.2ms	lat=18536.7ms
[2/20]	req#2	in=1024	out=25	status=ok	ttft=3952.1ms	lat=27872.6ms
[3/20]	req#8	in=1024	out=24	status=ok	ttft=1156.2ms	lat=13746.0ms
[4/20]	req#10	in=1024	out=29	status=ok	ttft=955.5ms	lat=11786.0ms
[5/20]	req#1	in=1024	out=64	status=ok	ttft=2294.7ms	lat=49072.9ms
[6/20]	req#0	in=1024	out=64	status=ok	ttft=3700.5ms	lat=52469.0ms
[7/20]	req#3	in=917	out=64	status=ok	ttft=2169.6ms	lat=44506.9ms
[8/20]	req#4	in=1024	out=64	status=ok	ttft=2374.1ms	lat=43307.3ms
[9/20]	req#6	in=1024	out=64	status=ok	ttft=5883.7ms	lat=40557.9ms
[10/20]	req#5	in=1024	out=64	status=ok	ttft=3449.2ms	lat=41029.9ms
[11/20]	req#13	in=1024	out=8	status=ok	ttft=1521.3ms	lat=7844.3ms
[12/20]	req#16	in=1024	out=8	status=ok	ttft=1066.7ms	lat=4986.6ms
[13/20]	req#9	in=1024	out=64	status=ok	ttft=672.2ms	lat=33193.3ms
[14/20]	req#18	in=1024	out=8	status=ok	ttft=639.3ms	lat=3812.8ms
[15/20]	req#15	in=1024	out=24	status=ok	ttft=1045.8ms	lat=12051.7ms
[16/20]	req#19	in=1024	out=41	status=ok	ttft=808.3ms	lat=11609.2ms
[17/20]	req#11	in=1024	out=64	status=ok	ttft=1060.5ms	lat=25836.4ms
[18/20]	req#14	in=1024	out=64	status=ok	ttft=1414.1ms	lat=23812.2ms
[19/20]	req#12	in=1024	out=64	status=ok	ttft=1680.4ms	lat=24803.3ms
[20/20]	req#17	in=1024	out=64	status=ok	ttft=1119.2ms	lat=20658.2ms

截图2b 逐请求结果汇总与统计

结果：成功率 20/20 = 100%，总墙钟 72.8 s，输出吞吐 12.28 tok/s，TTFT 均值 2113.5 ms (p50 1414.1 ms, p90 3952.1 ms)，端到端时延均值 25574.7 ms (p50 23812.2 ms, p90 44506.9 ms)。

截图2b · 逐请求结果汇总与统计

20/20 success | 72.8s | 12.28 tok/s

\$ # ---- 承上: 逐请求结果汇总与统计 ----

=====

Mooncake trace 采样 workload - 逐请求结果

=====

#	arrive(s)	in_tok	out_tok	status	TTFT(ms)	latency(ms)
0	0.23	1024	64	ok	3700.5	52469.0
1	3.63	1024	64	ok	2294.7	49072.9
2	4.82	1024	25	ok	3952.1	27872.6
3	8.20	917	64	ok	2169.6	44506.9
4	10.51	1024	64	ok	2374.1	43307.3
5	12.78	1024	64	ok	3449.2	41029.9
6	13.25	1024	64	ok	5883.7	40557.9
7	13.83	1024	23	ok	5307.2	18536.7
8	21.65	1024	24	ok	1156.2	13746.0
9	26.95	1024	64	ok	672.2	33193.3
10	30.22	1024	29	ok	955.5	11786.0
11	46.17	1024	64	ok	1060.5	25836.4
12	47.61	1024	64	ok	1680.4	24803.3
13	47.77	1024	8	ok	1521.3	7844.3
14	48.60	1024	64	ok	1414.1	23812.2
15	50.23	1024	24	ok	1045.8	12051.7
16	50.92	1024	8	ok	1066.7	4986.6
17	52.15	1024	64	ok	1119.2	20658.2
18	56.33	1024	8	ok	639.3	3812.8
19	58.76	1024	41	ok	808.3	11609.2

=====

采样来源 : Mooncake FAST'25 arxiv-trace/mooncake_trace.jsonl (共 23608 条, 随机采样 20 条, seed=2026)

到达过程 : Poisson, λ=0.5000 req/s (平均间隔 2.00s)

公共前缀 : 256 tokens (模拟 trace 中共享的 hash_ids[0], 触发 RadixCache 复用)

成功率 : 20/20 = 100.0% 总墙钟 72.8s 输出吞吐 12.28 tok/s

TTFT(ms) : avg=2113.5 p50=1414.1 p90=3952.1 min=639.3 max=5883.7

Latency : avg=25574.7ms p50=23812.2ms p90=44506.9ms

=====

结果已保存: /mnt/d/first-task/work/results/benchmark_results.json

/mnt/d/first-task/work/results/benchmark_results.csv

附录 服务端 RadixCache 前缀复用证据

服务端 Prefill batch 日志中 `#cached-token > 0` 即表示该请求已有前缀命中 RadixCache、对应的 prefill 计算被直接跳过。实验令所有压测请求共享 **256 token** 公共前缀（对应 Mooncake trace 中普遍共享的 `hash_ids[0]`：该字段在 23608 条记录中 仅取 4 个不同值，最常见者占 46.3%）。全程 **38 个 prefill 批次中有 29 个命中，占比 76.3%**；命中长度以 256（即共享前缀长度）与 1023/1024（整段 prompt 已被缓存）为主。同时可见：大批次（`#new-token ≥ 600`，共 12 个）时服务端自报 prefill 输入吞吐为 **214~423 tok/s**；小批次的瞬时值受 1 秒时间粒度限制，不具参考意义。

附录 · 服务端 RadixCache 前缀复用证据sglang_server.log

```
$ grep "Prefill batch" /mnt/d/first-task/work/logs/sglang_server.log | tail -20
$ # 只保留与本问题相关的字段: #new-seq / #new-token / #cached-token / #running-req

10:51:15 #new-seq:1 #new-token:661 #cached-token:256 #running-req:3
10:51:18 #new-seq:1 #new-token:745 #cached-token:279 #running-req:4
10:51:21 #new-seq:1 #new-token:767 #cached-token:257 #running-req:5
10:51:24 #new-seq:2 #new-token:769 #cached-token:1279 #running-req:6
10:51:28 #new-seq:1 #new-token:1 #cached-token:1023 #running-req:8
10:51:33 #new-seq:1 #new-token:1 #cached-token:1023 #running-req:9
10:51:36 #new-seq:1 #new-token:1 #cached-token:1023 #running-req:10
10:51:52 #new-seq:1 #new-token:1 #cached-token:1023 #running-req:7
10:51:54 #new-seq:2 #new-token:2 #cached-token:2046 #running-req:8
10:51:55 #new-seq:1 #new-token:1 #cached-token:1023 #running-req:10
10:51:56 #new-seq:1 #new-token:1 #cached-token:1023 #running-req:11
10:51:57 #new-seq:1 #new-token:1 #cached-token:1023 #running-req:12
10:51:58 #new-seq:1 #new-token:1 #cached-token:1023 #running-req:13
10:52:02 #new-seq:1 #new-token:1 #cached-token:1023 #running-req:6
10:52:05 #new-seq:1 #new-token:1 #cached-token:1023 #running-req:7
10:53:28 #new-seq:1 #new-token:1 #cached-token:8 #running-req:0
10:53:46 #new-seq:1 #new-token:1 #cached-token:35 #running-req:0
10:54:05 #new-seq:1 #new-token:1 #cached-token:8 #running-req:0
10:59:28 #new-seq:1 #new-token:1 #cached-token:35 #running-req:0
10:59:44 #new-seq:1 #new-token:1 #cached-token:8 #running-req:0

# 读法: #cached-token > 0 表示该请求已有前缀命中 RadixCache，这部分 prefill 被直接跳过。
# 统计（全程 38 个 prefill 批次）：29 个批次命中，占比 76.3%。
# 命中长度常见 256（= 各请求共享的公共前缀长度），亦出现 1023/1024（整段 prompt 已缓存）。
# 未命中（=0）的批次 9 个，多出现在缓存被新前缀挤出或首个请求时。
```

说明：本页所有输出均取自真实运行日志与真实 HTTP 响应，未做人工改写。完整原始记录见仓库 `evidence/` 目录。

运行环境：WSL2 · Ubuntu 26.04.1 LTS · Intel Core Ultra 5 338H (12 vCPU) · 15 GiB RAM · SGLang 0.5.14 (源码编译, CPU/AVX2 基线) · Ray 2.56.0 · Qwen3-0.6B (bf16)