

使用的模型

会话内编码助手（平台标注 monkeycode-basic/qwen3.8-flash）。未把平台内部 LLM API Key 写入项目。

主要提示词类型

解析两份挑战 PDF；查阅 SGLang 0.5.14 启动方式、/generate、flush_cache、RadixCache.match_prefix；按交付目录生成脚本与 PDF；在无 GPU 环境下设计可核验的协议兼容服务。

AI 如何帮助学习

帮助定位 v0.5.14 源码文件与函数行号，把 RadixAttention 与 PagedAttention 的论文表述对齐到 pipeline 阶段，并生成可运行的采样/回放脚本。

使用场景与是否被误导

用于阅读文档、整理源码路径、生成样板脚本与排版 PDF。容易误导的点是默认环境已有 GPU/CUDA。实际用 nvidia-smi 与 nvcc 核验后改为 mock 服务，并在 README 标明。公式与源码行号均对照官方文档与 GitHub tag v0.5.14。