

### (1) 如何完成第一次挑战

先把 PDF 拆成可执行清单：起服务、打 /v1/models、单次推理截图、从 Mooncake JSONL 采样 20 条、按 input/output\_length 构造 prompt、用泊松过程生成到达时间、回放并记录 tokens/status/TTFT。本机无 NVIDIA GPU 与 CUDA，无法加载 Qwen3-0.6B 权重，因此实现了协议兼容的 mock-sglang：HTTP 面与 SGLang 一致，内部 RadixCache 按 token 插入/匹配，时延按未缓存 Prefill token 线性建模。用该服务跑通脚本，再对照 v 0.5.14 源码行号画流程图并写重点回答。迭代方式是先跑通接口，再补 workload 与文档。

### (2) 最困难的部分与克服方式

最困难的是把“必须用 SGLang 0.5.14 + GPU 模型”与“当前环境没有 GPU”对齐。克服方法是把作业拆成协议层与算子层：协议层完整实现并可复现；算子层用源码阅读 (TokenizerManager.generate\_request、Scheduler.event\_loop\_normal、RadixCache.match\_prefix) 补齐真实系统语义，并在 README 写明 GPU 上回放命令。

### (3) 从 0 到 1 的科研工作应包含什么，有何启发

应包含问题定义与度量 (TTFT/吞吐/命中率)、可复现 workload (公开 trace)、系统实现或受控对比、以及把公式与数据对上的分析。启发是：先有可复现实验与指标，再谈优化；前缀复用这类工作必须同时看算法 (树/哈希) 和系统 (调度、分页、淘汰)。