

SGLang / RadixAttention (NeurIPS 2024)

前端控制语言加 SRT 运行时。核心是用 radix tree 缓存 KV，跨请求共享前缀。match_prefix 最长命中，insert 时可能 split，lock_ref 保护 in-flight 节点，LRU 从叶子淘汰。与普通 HF generate 相比，共享系统提示时 Prefill 可数量级下降。

vLLM / PagedAttention (SOSP 2023)

把 KV 看成操作系统虚拟内存：逻辑 block 映射物理 block，解决预留浪费与碎片。连续批处理的基础。前缀缓存后来以 block hash 形式加入，粒度是定长块。

Mooncake FAST'25 Trace

每条记录含 timestamp、input_length、output_length、hash_ids。块大小 512。相同 hash_ids 表示可复用前缀块。arxiv-trace/mooncake_trace.jsonl 是技术报告历史版本。本作业从中采样 20 条，截断到 Qwen3-0.6B 可承受长度，并用泊松过程重生成到达时间。

SGLang 文档要点

启动：python -m sglang.launch_server --model-path Qwen/Qwen3-0.6B --host 0.0.0.0 --port 30000。默认 Radix Cache 开启。原生 /generate 返回 text 与 meta_info (prompt_tokens、completion_tokens、cached_tokens)。POST /flush_cache 清空树。