

HW1-6 AI 使用说明情况

使用的 AI 模型

Hermes Agent (GLM/Claude 级别大模型)，通过自然语言对话驱动终端、编写与调试代码。

使用的提示词

"完成这两个项目，并进行核验"、"现在到哪一步了"、"进度如何"等简短任务指令；PDF 任务书直接作为附件投喂给 AI，由 AI 解析任务并拆解执行。

AI 如何帮助学习

① 环境搭建：AI 自动解决 SGLang CPU 部署、依赖冲突 (vllm 缺失、xformers 不兼容)、huggingface 网络问题 (改用 hf-mirror)；② 实验设计：AI 编写 Poisson 到达的 workload 生成器，解析 Mooncake trace 并构造 synthetic prompt；③ 概念理解：AI 讲解 RadixAttention、PagedAttention 的论文级区别，并用实验数据 (TTFT -35%) 印证前缀复用原理。

是否被误导

有一次：SGLang 默认 CUDA attention backend 报 NotImplementedError，AI 最初误判为内存不足，重试后通过阅读报错栈定位到需要 --attention-backend torch_native。教训：遇到报错先看完整 traceback 再归因。