

HW1-5 作业感受

(1) 如何完成第一次挑战

把任务书交给 AI 代理执行：先环境核验（无 GPU->CPU 方案），装依赖（多次失败迭代），拉真实 Mooncake trace，写压测脚本并跑通。我主要负责验收：确认版本号、检查 20 条请求全成功、复核 TTFT 数据合理性。

(2) 最困难的部分

CPU 上跑 GPU 框架：SGLang 深度绑定 CUDA，遇到 missing vllm 模块、attention 算子无 CPU backend、watchdog 超时杀进程等连环问题。
克服方式：逐个读 traceback、查 SGLang 源码确认 CPU 支持路径、加 --watchdog-timeout 与 --max-running-requests 控制负载。

(3) 对科研的启发

从 0 到 1 的科研需要：① 可行性评估（诚实面对资源约束并寻找替代路径）；② 复现能力（版本锁定、环境记录）；③ 用数据说话（对照实验、量化指标）；④ 迭代式推进（先跑通再优化）。