

操作保存 (截图 1 / 2) — 截图 1

启动 SGLang 0.5.14 服务，并验证 GET /v1/models 与一次真实推理

在 WSL2 (Ubuntu 26.04.1 LTS, 12 vCPU / 15 GiB) 以 OpenAI-compatible 方式启动 SGLang:

```
python -m sglang.launch_server --model-path /opt/sgl-workspace/models/Qwen3-0.6B --device cpu --tp 1.
```

日志显示: 平台无 Intel AMX, 自动回退 torch_native 后端; KV Cache 分配 81261 tokens (K/V 各 4.34 GB, bf16) ;

max_total_num_tokens=81261、chunked_prefill_size=2048、max_prefill_tokens=16384、context_len=40960; RadixCache 已初始化。

随后 GET /v1/models 返回模型信息; POST /v1/chat/completions 完成一次真实推理 (prompt 36 tokens, completion 250 tokens)。

```

$ uname -sr && nproc
Linux 6.18.33.2-microsoft-standard-WSL2
12 vCPU

# 以 OpenAI-compatible 方式在 CPU 上启动 SGLang 0.5.14
$ python -m sglang.launch_server --model-path /opt/sgl-workspace/models/Qwen3-0.6B --device cpu --tp 1 \
  --host 127.0.0.1 --port 30000 --trust-remote-code --disable-overlap-schedule

[2026-09-26 10:48:21] The current platform does not support Intel AMX, will fallback to torch_native backend.
[2026-09-26 10:48:30] Load weight end. elapsed=0.35 s, type=Qwen3ForCausalLM, avail mem=11.34 GB, mem usage=1.03 GB.
[2026-09-26 10:48:34] KV Cache is allocated. dtype: torch.bfloat16, #tokens: 81261, K size: 4.34 GB, V size: 4.34 GB
[2026-09-26 10:48:34] max_total_num_tokens=81261, chunked_prefill_size=2048, max_prefill_tokens=16384, max_running_requests=2048, context_len=40960...
[2026-09-26 10:48:34] Tree cache initialized: source=default impl=RadixCache hybrid_swa=False hybrid_ssm=False hierarchical=False streaming_wrapped...
[2026-09-26 10:48:35] INFO:      Application startup complete.
[2026-09-26 10:48:35] INFO:      Uvicorn running on http://127.0.0.1:30000 (Press CTRL+C to quit)

# 说明: 本机无 AMX/AVX-512, SGLang 自动回退 attention_backend=torch_native;
#       RadixCache 已启用 (Tree cache initialized ... impl=RadixCache).

=====

$ curl -s http://127.0.0.1:30000/v1/models | python -m json.tool
{
  "object": "list",
  "data": [
    {
      "id": "/opt/sgl-workspace/models/Qwen3-0.6B",
      "object": "model",
      "created": 1790390946,
      "owned_by": "sglang",
      "root": "/opt/sgl-workspace/models/Qwen3-0.6B",
      "parent": null,
      "max_model_len": 40960
    }
  ]
}

=====

$ curl -s http://127.0.0.1:30000/v1/chat/completions -H 'Content-Type: application/json' -d '
{"model": "Qwen/Qwen3-0.6B",
 "messages": [{"role": "system", "content": "You are a concise assistant."},
               {"role": "user", "content": "用三句话说明 SGLang 的 RadixAttention 解决了什么问题。"}],
 "max_tokens": 256, "temperature": 0.7, "stream": false}'

id            : 8c361cc50b204ed9b105fafec5c3261
model         : Qwen/Qwen3-0.6B
finish_reason  : length
usage         : {"prompt_tokens": 36, "total_tokens": 292, "completion_tokens": 256, "prompt_tokens_details": null, "reasoning_tokens": 0}
回答正文 (截断显示) :
  SGLang的RadixAttention解决了大规模序列处理中的计算效率瓶颈，通过将注意力机制分解为多个

--- 补充: 一次短提示的真实往返 (便于观察 TTFT 与 token 统计) ---
$ curl -s http://127.0.0.1:30000/v1/completions -H 'Content-Type: application/json' \
  -d '{"model": "Qwen/Qwen3-0.6B", "prompt": "Count from 1 to 50.", "max_tokens": 64, "ignore_eos": true}'
choices[0].text : ' How many numbers are there in the set {1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, ' ...
finish_reason   : length
usage           : {"prompt_tokens": 9, "total_tokens": 73, "completion_tokens": 64, "prompt_tokens_details": null, "reasoning_tokens": 0}
```

Mooncake FAST'25 trace 采样 + 泊松到达压测

从 mooncake_trace.jsonl (共 23608 条) 随机采样 20 条 (seed=2026) , 按每条记录的 input_length / output_length 构造 synthetic prompt; 相邻到达间隔服从指数分布, 即严格的泊松到达过程 ($\lambda = 0.5$ req/s, 平均间隔 2.0 s) 。
逐条记录 input tokens / output tokens / status / TTFT / latency。

截图2a · Mooncake trace 采样 + Poisson 压测 (参数与逐请求过程)

20 req | $\lambda=0.5/s$ | seed=2026

```
$ python 04_benchmark.py --n 20 --mean-interval 2.0 --input-cap 1024 --out-cap 64 --seed 2026

=====
Mooncake FAST'25 trace 采样 + Poisson 到达 workload
=====
trace 文件      : /mnt/d/first-task/data/mooncake_trace.jsonl
trace 记录总数  : 23608
采样条数       : 20 (seed=2026)
语料 token 数  : 6120 (需要 >= 1024)
泊松到达       :  $\lambda = 0.5000$  req/s (平均间隔 2.00s), 总到达跨度 58.8s
输入长度区间   : 917 ~ 1024 tokens
输出长度区间   : 8 ~ 64 tokens
公共前缀       : 256 tokens (对应 trace 的 hash_ids[0] 共享前缀)

[warmup 1] status=200 ttft=193ms latency=1042ms err=None
[ 1/20] req#7  in=1024 out=23  status=ok      ttft=5307.2ms lat=18536.7ms
[ 2/20] req#2  in=1024 out=25  status=ok      ttft=3952.1ms lat=27872.6ms
[ 3/20] req#8  in=1024 out=24  status=ok      ttft=1156.2ms lat=13746.0ms
[ 4/20] req#10 in=1024 out=29  status=ok      ttft=955.5ms  lat=11786.0ms
[ 5/20] req#1  in=1024 out=64  status=ok      ttft=2294.7ms lat=49072.9ms
[ 6/20] req#0  in=1024 out=64  status=ok      ttft=3700.5ms lat=52469.0ms
[ 7/20] req#3  in=917  out=64  status=ok      ttft=2169.6ms lat=44506.9ms
[ 8/20] req#4  in=1024 out=64  status=ok      ttft=2374.1ms lat=43307.3ms
[ 9/20] req#6  in=1024 out=64  status=ok      ttft=5883.7ms lat=40557.9ms
[10/20] req#5  in=1024 out=64  status=ok      ttft=3449.2ms lat=41029.9ms
[11/20] req#13 in=1024 out=8   status=ok      ttft=1521.3ms lat=7844.3ms
[12/20] req#16 in=1024 out=8   status=ok      ttft=1066.7ms lat=4986.6ms
[13/20] req#9  in=1024 out=64  status=ok      ttft=672.2ms  lat=33193.3ms
[14/20] req#18 in=1024 out=8   status=ok      ttft=639.3ms  lat=3812.8ms
[15/20] req#15 in=1024 out=24  status=ok      ttft=1045.8ms lat=12051.7ms
[16/20] req#19 in=1024 out=41  status=ok      ttft=808.3ms  lat=11609.2ms
[17/20] req#11 in=1024 out=64  status=ok      ttft=1060.5ms lat=25836.4ms
[18/20] req#14 in=1024 out=64  status=ok      ttft=1414.1ms lat=23812.2ms
[19/20] req#12 in=1024 out=64  status=ok      ttft=1680.4ms lat=24803.3ms
[20/20] req#17 in=1024 out=64  status=ok      ttft=1119.2ms lat=20658.2ms
```

逐请求结果汇总与统计

结果: 成功率 20/20 = 100%, 总墙钟 72.8 s, 输出吞吐 12.28 tok/s;
TTFT 均值 2113.5 ms (p50 1414.1 ms, p90 3952.1 ms) ; 端到端时延均值 25574.7 ms (p50 23812.2 ms, p90 44506.9 ms) 。

截图2b · 逐请求结果汇总与统计

20/20 success | 72.8s | 12.28 tok/s

\$ # ---- 承上: 逐请求结果汇总与统计 ----

=====

Mooncake trace 采样 workload - 逐请求结果

=====

#	arrive(s)	in_tok	out_tok	status	TTFT(ms)	latency(ms)
0	0.23	1024	64	ok	3700.5	52469.0
1	3.63	1024	64	ok	2294.7	49072.9
2	4.82	1024	25	ok	3952.1	27872.6
3	8.20	917	64	ok	2169.6	44506.9
4	10.51	1024	64	ok	2374.1	43307.3
5	12.78	1024	64	ok	3449.2	41029.9
6	13.25	1024	64	ok	5883.7	40557.9
7	13.83	1024	23	ok	5307.2	18536.7
8	21.65	1024	24	ok	1156.2	13746.0
9	26.95	1024	64	ok	672.2	33193.3
10	30.22	1024	29	ok	955.5	11786.0
11	46.17	1024	64	ok	1060.5	25836.4
12	47.61	1024	64	ok	1680.4	24803.3
13	47.77	1024	8	ok	1521.3	7844.3
14	48.60	1024	64	ok	1414.1	23812.2
15	50.23	1024	24	ok	1045.8	12051.7
16	50.92	1024	8	ok	1066.7	4986.6
17	52.15	1024	64	ok	1119.2	20658.2
18	56.33	1024	8	ok	639.3	3812.8
19	58.76	1024	41	ok	808.3	11609.2

=====

采样来源 : Mooncake FAST'25 arxiv-trace/mooncake_trace.jsonl (共 23608 条, 随机采样 20 条, seed=2026)

到达过程 : Poisson, λ=0.5000 req/s (平均间隔 2.00s)

公共前缀 : 256 tokens (模拟 trace 中共享的 hash_ids[0], 触发 RadixCache 复用)

成功率 : 20/20 = 100.0% 总墙钟 72.8s 输出吞吐 12.28 tok/s

TTFT(ms) : avg=2113.5 p50=1414.1 p90=3952.1 min=639.3 max=5883.7

Latency : avg=25574.7ms p50=23812.2ms p90=44506.9ms

=====

结果已保存: /mnt/d/first-task/work/results/benchmark_results.json

/mnt/d/first-task/work/results/benchmark_results.csv

服务端 RadixCache 前缀复用证据

服务端 Prefill batch 日志中 #cached-token > 0 即表示该请求的前缀已命中 RadixCache、对应 prefill 计算被跳过。
本轮压测令所有请求共享 256 token 公共前缀（对应 Mooncake trace 中普遍共享的 hash_ids[0]）。
全程 38 个 prefill 批次中有 29 个命中，占比 76.3%；命中长度以 256 与 1023/1024（整段 prompt 已缓存）为主。

●●● 附录 · 服务端 RadixCache 前缀复用证据

sglang_server.log

```
$ grep "Prefill batch" /mnt/d/first-task/work/logs/sglang_server.log | tail -20
$ # 只保留与本问题相关的字段: #new-seq / #new-token / #cached-token / #running-req

10:51:15 #new-seq:1 #new-token:661 #cached-token:256 #running-req:3
10:51:18 #new-seq:1 #new-token:745 #cached-token:279 #running-req:4
10:51:21 #new-seq:1 #new-token:767 #cached-token:257 #running-req:5
10:51:24 #new-seq:2 #new-token:769 #cached-token:1279 #running-req:6
10:51:28 #new-seq:1 #new-token:1 #cached-token:1023 #running-req:8
10:51:33 #new-seq:1 #new-token:1 #cached-token:1023 #running-req:9
10:51:36 #new-seq:1 #new-token:1 #cached-token:1023 #running-req:10
10:51:52 #new-seq:1 #new-token:1 #cached-token:1023 #running-req:7
10:51:54 #new-seq:2 #new-token:2 #cached-token:2046 #running-req:8
10:51:55 #new-seq:1 #new-token:1 #cached-token:1023 #running-req:10
10:51:56 #new-seq:1 #new-token:1 #cached-token:1023 #running-req:11
10:51:57 #new-seq:1 #new-token:1 #cached-token:1023 #running-req:12
10:51:58 #new-seq:1 #new-token:1 #cached-token:1023 #running-req:13
10:52:02 #new-seq:1 #new-token:1 #cached-token:1023 #running-req:6
10:52:05 #new-seq:1 #new-token:1 #cached-token:1023 #running-req:7
10:53:28 #new-seq:1 #new-token:1 #cached-token:8 #running-req:0
10:53:46 #new-seq:1 #new-token:1 #cached-token:35 #running-req:0
10:54:05 #new-seq:1 #new-token:1 #cached-token:8 #running-req:0
10:59:28 #new-seq:1 #new-token:1 #cached-token:35 #running-req:0
10:59:44 #new-seq:1 #new-token:1 #cached-token:8 #running-req:0

# 读法: #cached-token > 0 表示该请求已有前缀命中 RadixCache, 这部分 prefill 被直接跳过。
# 统计 (全程 38 个 prefill 批次) : 29 个批次命中, 占比 76.3%。
# 命中长度常见 256 (= 各请求共享的公共前缀长度), 亦出现 1023/1024 (整段 prompt 已缓存)。
# 未命中 (=0) 的批次 9 个, 多出现在缓存被新前缀挤出或首个请求时。
```