

HW1-1/2 操作记录（截图对应说明）

服务启动

```
sglang.launch_server --model-path Qwen/Qwen3-0.6B --device cpu --attention-backend torch_native --mem-fraction-static 0.8 --watchdog-timeout 100000 --max-running-requests 8 --port 30000
```

/v1/models 访问

```
curl http://127.0.0.1:30000/v1/models -> 返回 Qwen/Qwen3-0.6B（结果存 results/models.json，即截图1内容）
```

推理请求

POST /v1/chat/completions，成功生成回答（results/inference_response.json，截图1）

Workload 实验

python src/run_workload.py：从 22441 条 Mooncake arxiv trace 采样 20 条，按 input_length 构造 synthetic prompt，Poisson($\lambda=0.5/s$) 到达，流式发送 /generate。20/20 成功，逐请求 input/output tokens、status、latency 记录于 results/workload_results.jsonl（截图2）。

环境

Ubuntu 24.04, Python 3.11.16, SGLang 0.5.14, Ray 2.56.0, torch CPU, 2 vCPU / 7.4GB RAM（无 GPU）。