

HW1-3 一次请求经过 SGLang 在线推理框架的流程

流程（重点在流程）

Client 发送 HTTP 请求 -> FastAPI 接收 -> TokenizerManager: 文本 tokenize 成 input_ids, 构造 Req 对象 -> ZMQ 发送给 Scheduler -> Scheduler.waiting_queue 排队 -> 调度器按策略取请求组 Prefill batch -> RadixCache.match_prefix: 前缀匹配, 命中的 KV 直接复用 -> 未命中部分执行 Prefill (并行算 QKV, 产出首个 token) -> KV 写入 token pool / RadixCache -> 进入 running batch 逐 token Decode (自回归, 每步读全部历史 KV, 只算最新 token) -> 采样 (temperature/top-p) -> TokenizerManager 增量反解码 -> TokenizerManager 流式 (chunked) 返回 -> 请求结束, cache_finished_req 把本请求 KV 按 token 前缀写回 RadixCache 供后续请求复用 -> metrics 上报

关键优化点

RadixAttention: 以 radix 树管理 KV cache, 自动识别并复用任意公共前缀; page-sized KV cache: KV 以页为粒度分配, 显存管理高效; Prefix Reuse: 多轮对话/公共 system prompt 场景 Prefill 大幅减少。