

一次请求在 SGLang 在线推理框架中的完整流程

client → tokenizer → scheduler / queue → prefill → KV Cache / RadixCache → decode iterations → sampling → streaming output → metric

(HW1 挑战内容 3)

