

AI 使用说明情况（第二次挑战）

使用的 AI 模型：会话内编码助手（平台标注 monkeycode-basic/qwen3.8-flash）。未向项目写入任何平台 LLM API Key。

主要提示词：解析第二次挑战 PDF；实现 /generate + input_ids + 流式测量；对照表字段；RadixCache.match_prefix 与 TokenizerManager.generate_request 在 v0.5.14 的文件位置；交付目录 HW2-0102603133。

AI 如何帮助学习：把作业参数翻译成可执行脚本与检查断言；把源码主线对齐到函数行号；生成报告排版。学习重点是前缀复用的注意力公式与调度器匹配路径。

是否被误导：默认假设可启动真实 SGLang GPU 服务。实际环境无 GPU / nvcc。处理方式是实现协议兼容服务核验脚本正确性，并在 README 给出真实 GPU 启动命令。任务二行号均对照 GitHub tag v0.5.14，未采信未核对的博客行号。作业感受（2）（3）按题目要求由完成过程直接撰写。