

作业感受（第二次挑战）

HW2 第五部分

（1）简述你是如何完成第二次挑战的

这一次的关键词是"对照"。我先按题目要求把实验口径定死：两组各 32 条请求、并发 8、输入固定 1024 token（共享前缀 896 + 各自后缀 128）、`max_new_tokens=16`、`temperature=0`、`ignore_eos=true`、`sampling_seed=2026`，除"前缀能否复用"外全部保持一致，然后用脚本把流程固化下来：服务预热 → 等待空闲 → `POST /flush_cache` 并校验返回 → 共享前缀组额外发一条预热请求 → 并发回放。采集指标时我特意区分了客户端计时（TTFT/TPOT/E2E）与服务端 `meta_info`（`cached_tokens`），这样"命中了多少"与"快了多少"能互相对照。

中途踩了三个坑，都是靠"让脚本自己报错"发现的：一是把 `/flush_cache` 的返回判错，脚本一直认为服务不空闲；二是第一版"分散前缀"其实生成了相同文本，分散组命中率高达 74.9%，我加了"最长公共前缀自检"才暴露出来，改成分散语料后降到 0.56%；三是容器内存限额只有 8 GB，KV 池开大了会被 OOM 杀掉。修完后两组各跑 3 轮，结果非常稳定（命中率三轮完全一致），才开始动笔写报告。AI 在其中主要扮演"报错解释器 + 源码导航 + 文档骨架"的角色，而实验设计、指标口径与结论判断都是我自己定的。

（2）你觉得哪部分工作最困难，你是如何克服这个困难的

【本小题作业要求禁止 AI 辅助撰写，以下为空白模板，请由本人手写填写后替换】

最困难的部分：

我是这样克服的：

（3）你觉得类似的从 0 到 1 的科研工作，需要包含哪些方面的研究，对你今后的科研工作有什么启发

【本小题作业要求禁止 AI 辅助撰写，以下为空白模板，请由本人手写填写后替换】

需要包含的研究方面：

对今后科研的启发：
